Introducción a Ciencia de Datos

Redes neuronales convolucionales

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Computer Vision
Redes convolucionales

Visión artificial

El campo del Computer Vision (visión maquina) busca poder **procesar imagenes y obtener distintos outputs de las mismas**. Es muy antiguo, pero los resultados previos al Deep Learning eran limitados.

En los **últimos años** con el poder del Deep Learning en aumento ha retomado fuerza.



Visión artificial

Podríamos probar a “extraer features” de las imágenes.



Ruedas
Puertas
Color



Puertas
Ventanas
Tipo de techo

Visión artificial

Extraer “features” de una imagen no es fácil por distintos problemas.

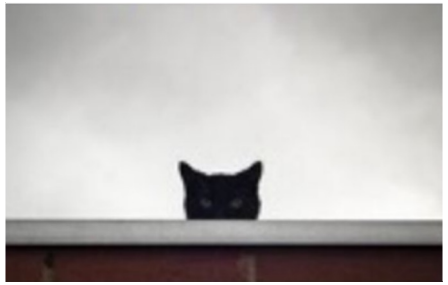
Variación del punto de vista



Deformaciones



Oclusiones



Variaciones de iluminación



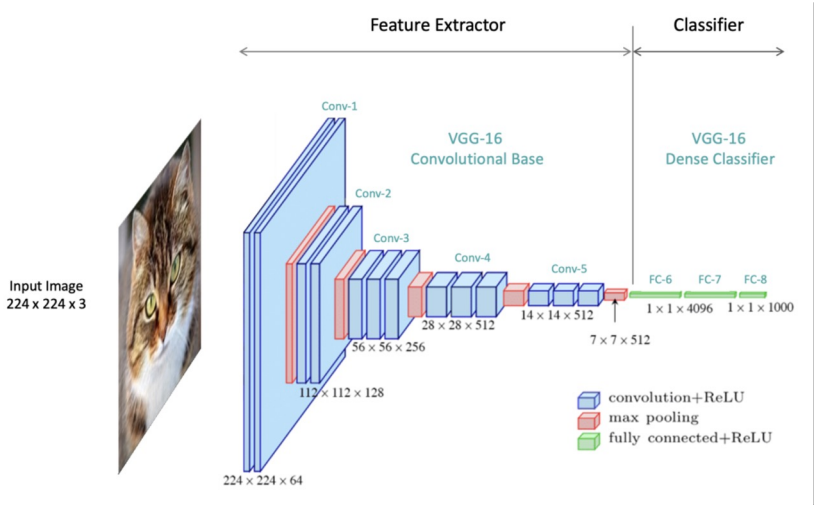
Fondos confusos



Variaciones intra clase



Qué es una Red Neuronal Convolucional



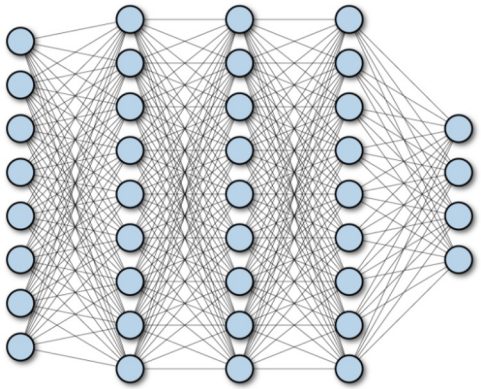
- Una **Red Neuronal Convolucional** (CNN) es un tipo de red neuronal diseñada específicamente para procesar datos con una estructura de grilla (imágenes).
- **Uso común:** Clasificación de imágenes, reconocimiento de objetos, visión por computadora.
- Las CNN fueron introducidas por Yann LeCun en los años 90 y revolucionaron el campo de la visión por computadora.
- Aunque inicialmente se usaban para clasificación de imágenes, hoy en día se aplican en muchos otros campos como **detección de objetos**, **segmentación semántica** y **procesamiento de audio**.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

¿Por qué CNN y no Redes Neuronales Densas?

Limitaciones de las Redes Neuronales Densas (Fully Connected Networks):

- Las redes densas tienen una **enorme cantidad de parámetros** cuando se aplican a imágenes, ya que cada píxel de la imagen está conectado a todas las neuronas de la capa siguiente.
- Esta estructura **no captura bien las relaciones espaciales** entre los píxeles (por ejemplo, un borde o un patrón).



¿Por qué CNN y no Redes Neuronales Densas?

Ventajas de las CNN:

- **Convoluciones locales:** A diferencia de las redes densas, las CNN exploran solo una pequeña ventana de la imagen a la vez (llamada filtro o kernel), lo que permite detectar características locales como bordes o texturas.
- **Reducción de parámetros:** Al aplicar el mismo filtro a diferentes regiones de la imagen, las CNN reducen significativamente la cantidad de parámetros.
- **Invariancia espacial:** Las CNN son más robustas a la traslación, ya que una característica (como un borde) puede ser detectada en diferentes partes de la imagen.

Componentes Principales de una CNN

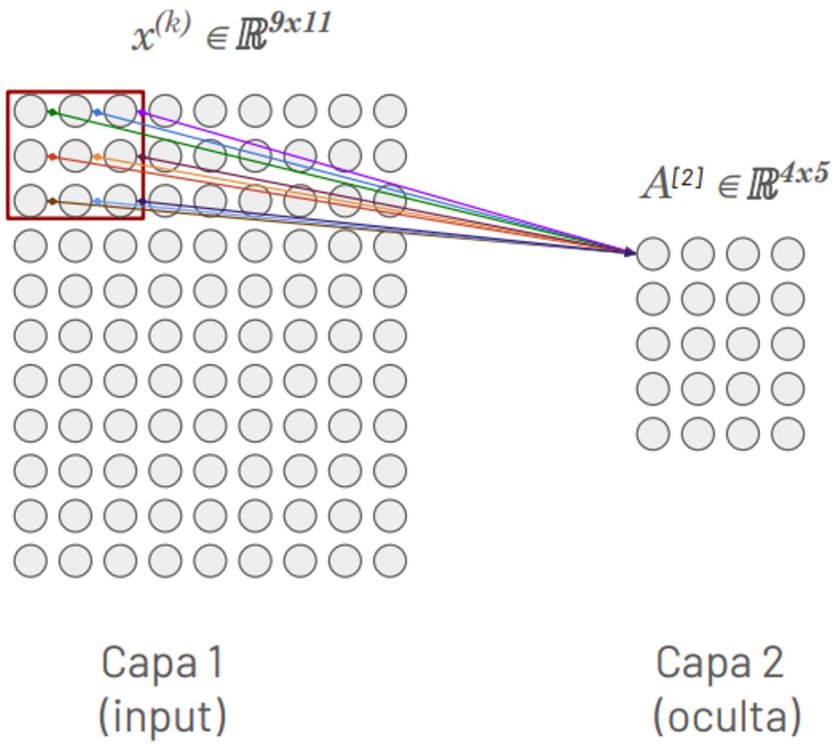
Capas Convolucionales:

- Aplican **filtros** sobre la imagen para extraer características, como bordes, esquinas o patrones más complejos.

- **Filtro/Kernal:** Un pequeño conjunto de pesos que se deslizan (convolucionan) sobre la imagen, detectando patrones específicos.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

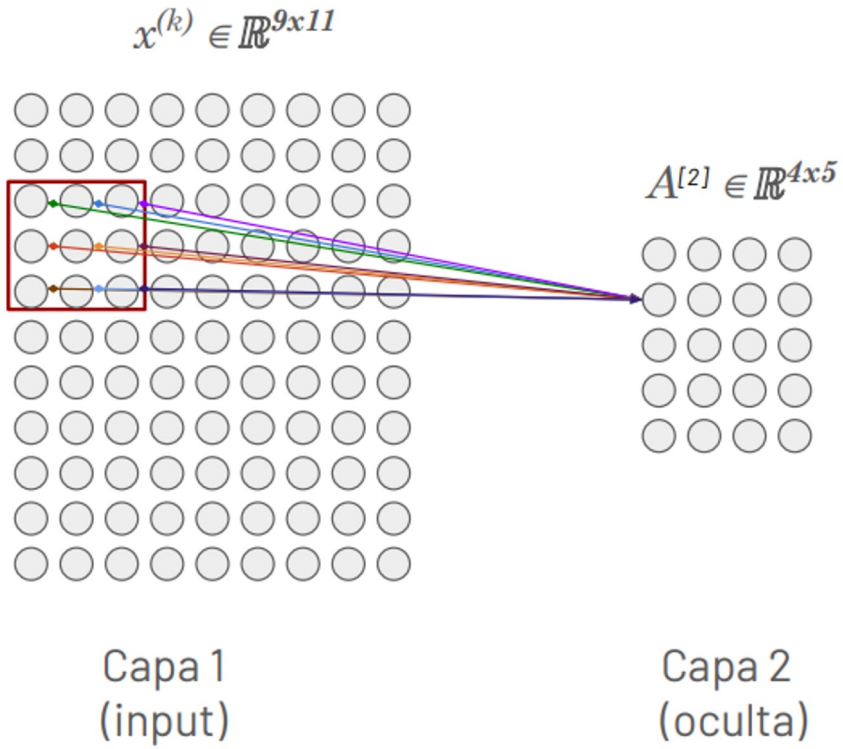
Componentes Principales de una CNN



- **Idea**: conectar “parches” del input a neuronas ocultas. Esas neuronas ocultas sólo ven los valores dentro del parche.
- Los parches son **ventanas deslizantes** (en este ejemplo, con tamaño 3x3 y salto 2) .
- La segunda capa tiene un **tamaño más reducido** (4x5). ¿Por qué?

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Componentes Principales de una CNN

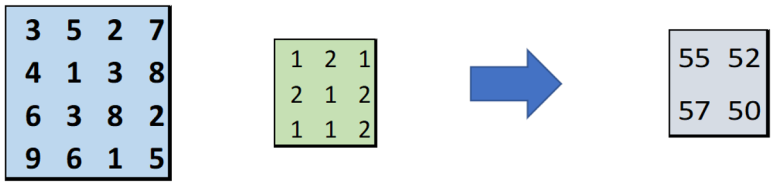


- **Idea**: conectar “parches” del input a neuronas ocultas. Esas neuronas ocultas sólo ven los valores dentro del parche.
- Los parches son **ventanas deslizantes** (en este ejemplo, con tamaño 3x3 y salto 2) .
- La segunda capa tiene un **tamaño más reducido** (4x5). ¿Por qué?

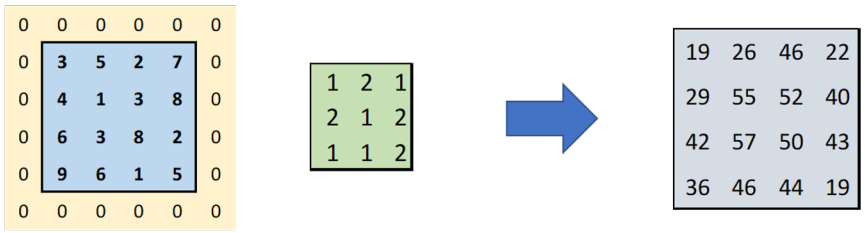
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Componentes Principales de una CNN

Padding: “valid”



Padding: “same”



Si se quiere evitar que la imagen se achique: “padding”, la **adición de píxeles extra** (generalmente ceros) alrededor de los bordes de una imagen antes de aplicar la convolución.

✓ Preservar la información de los bordes (full padding).
✓ Controlar el tamaño de la salida.
✓ Facilitar múltiples capas (evitando reducción)

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Componentes Principales de una CNN

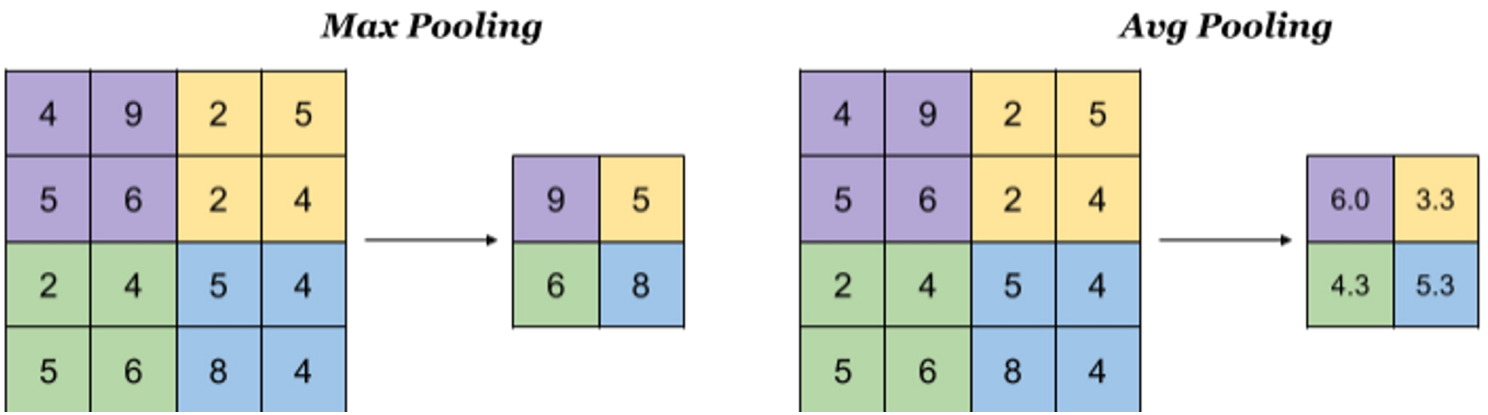
Capas de Pooling:

- **Reducen** la **dimensionalidad** de las características extraídas, manteniendo las más importantes.

- Los tipos más comunes son el **Max Pooling** (que selecciona el valor máximo en cada región) y el **Average Pooling** (que toma el promedio).

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

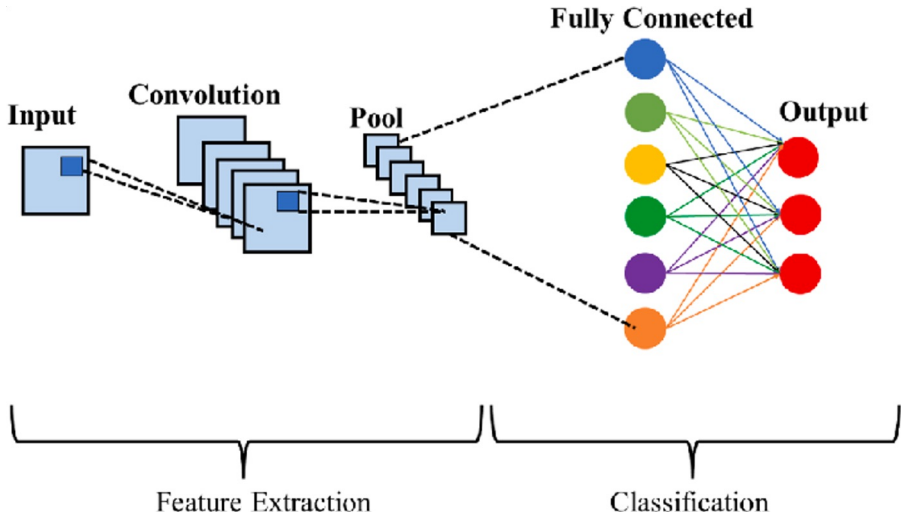
Componentes Principales de una CNN



Componentes Principales de una CNN

Capas Densas:

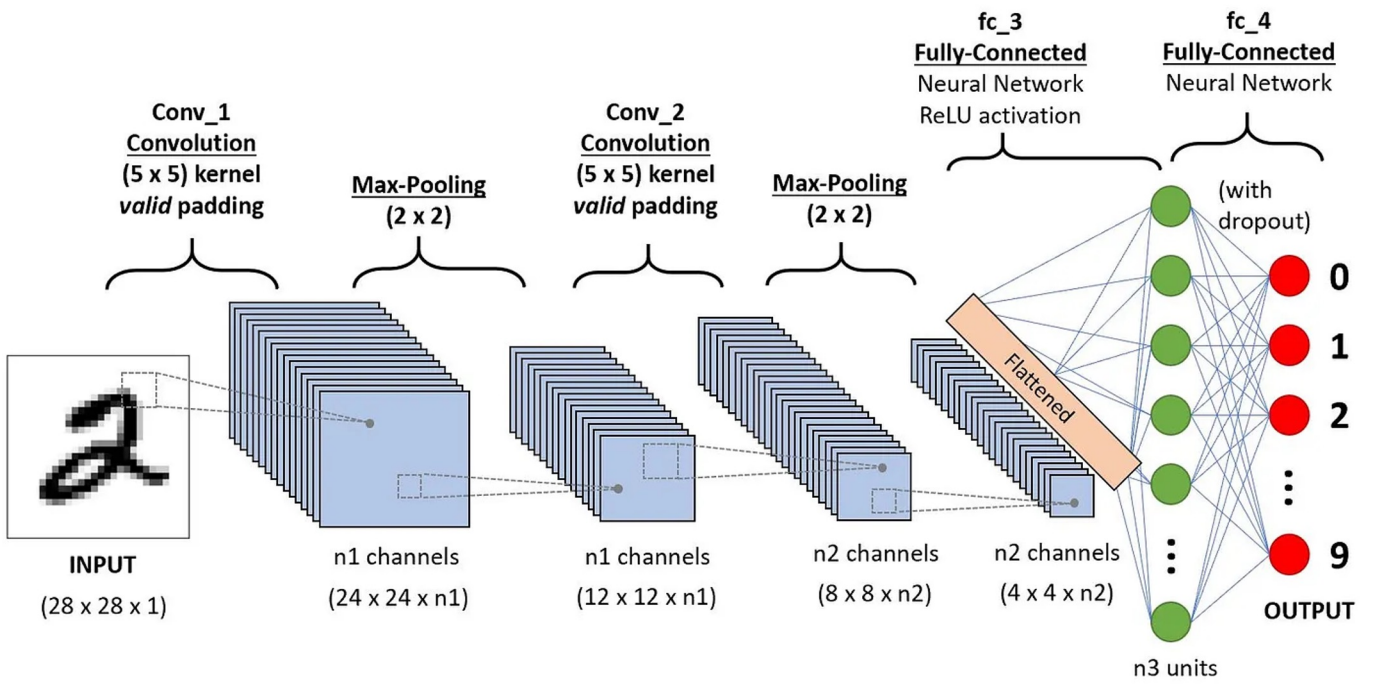
Después de las capas convolucionales y de pooling, las CNN suelen tener una o más capas densas (fully connected) que procesan las características extraídas para hacer la clasificación final.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Capas convolucionales

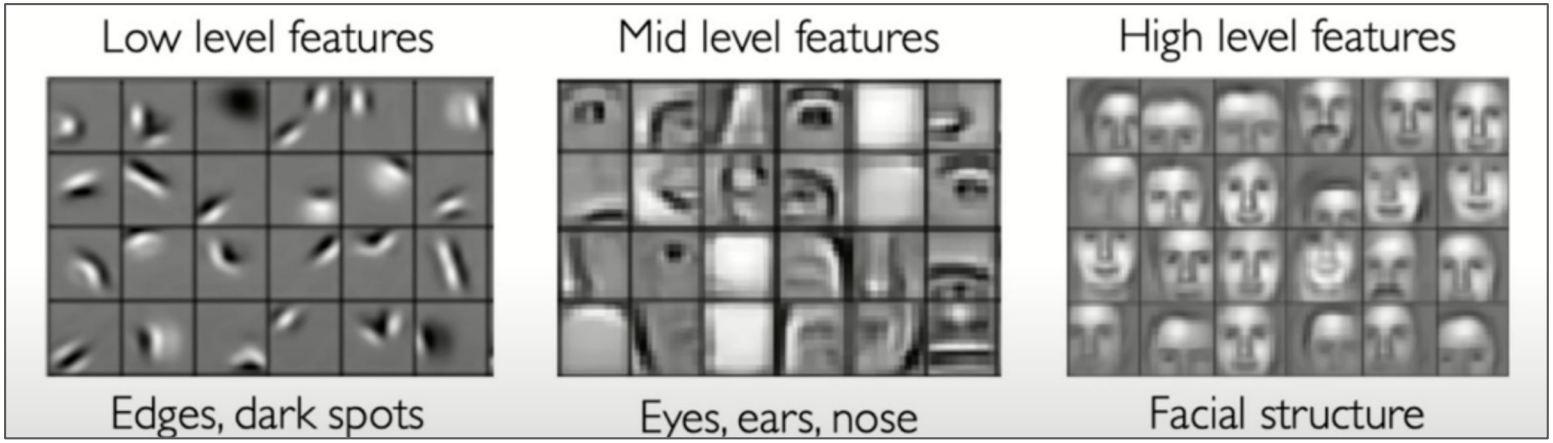
En general se usan varias capas convolucionales, que aprenden features cada vez más complejas.



Capas convolucionales

En esta figura se ven mapas de activación resultantes para tres tipos de filtros (de bajo, medio y alto nivel). Cada celda es el resultado de la operación sobre una imagen distinta.

A medida que tenemos capas convolucionales más profundas, la red es capaz de aprender representaciones más complejas.



https://adamharley.com/nn_vis/cnn/2d.html

¿Cómo Funciona una CNN?

1. **Entrada:**
   - Una imagen es convertida en una grilla de píxeles (generalmente representada como una matriz o tensor).
2. **Aplicación de Filtros (Convolución):**
   - La capa convolucional aplica múltiples filtros sobre la imagen, cada uno detectando un tipo específico de característica (como bordes horizontales, verticales, etc.).
3. **Reducción de la Dimensionalidad (Pooling):**
   - Después de la convolución, el pooling reduce la resolución de las características detectadas, lo que permite concentrarse en las más importantes y reducir el costo computacional.
4. **Clasificación:**
   - Finalmente, las capas densas toman la salida procesada de las capas convolucionales y producen una predicción, como la clase de una imagen (por ejemplo, qué dígito representa).

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

TensorFlow para Redes Convolucionales

TensorFlow y **Keras** simplifican la creación de redes convolucionales mediante capas predefinidas como Conv2D y MaxPooling2D.

Capas clave en una CNN:

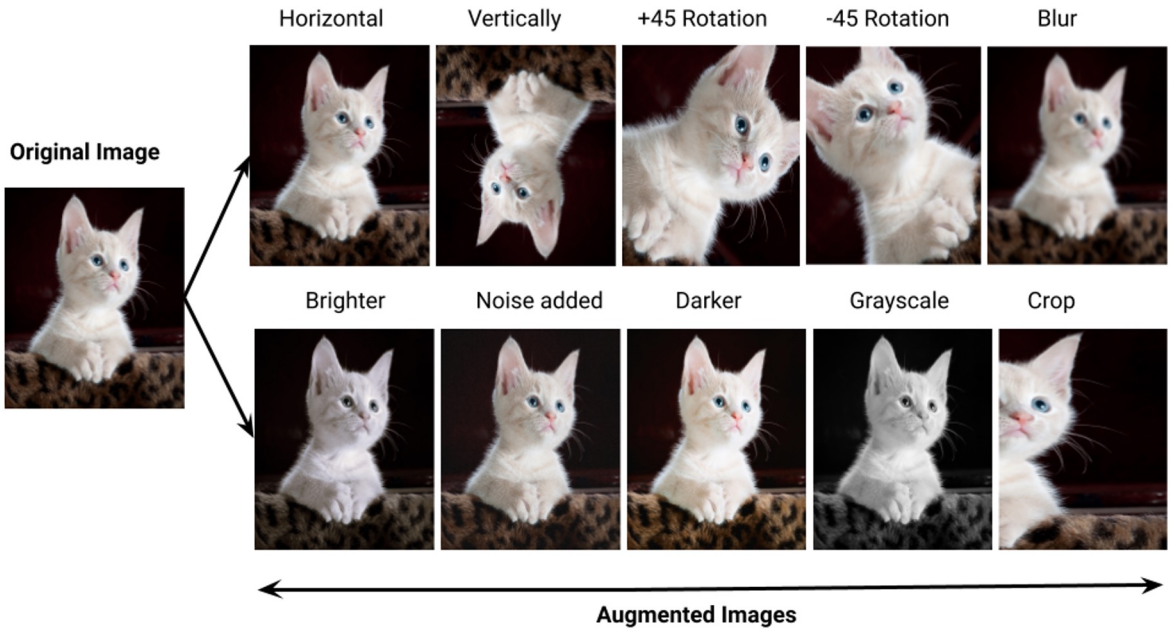
- Conv2D: Para aplicar la convolución.
- MaxPooling2D: Para reducir la dimensionalidad.
- Flatten: Para aplanar la salida antes de las capas densas.

```
[ ]  model = tf.keras.models.Sequential([
         tf.keras.layers.Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)),
         tf.keras.layers.MaxPooling2D((2, 2)),
         tf.keras.layers.Flatten(),
         tf.keras.layers.Dense(128, activation='relu'),
         tf.keras.layers.Dense(10, activation='softmax')
     ])
```

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

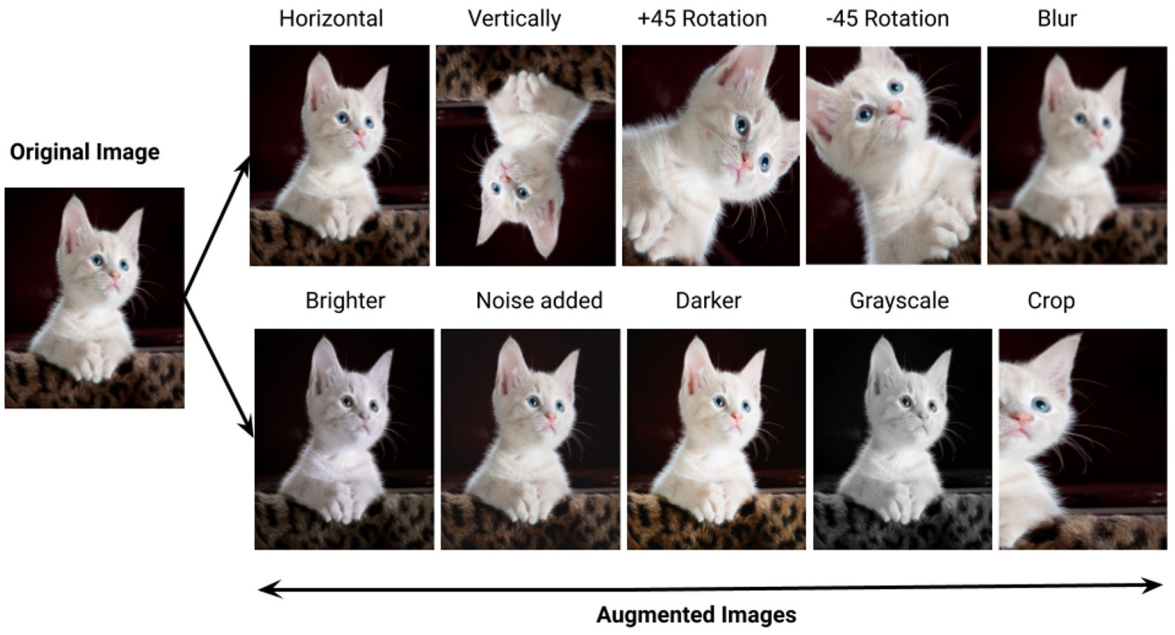
Data augmentation

- Proceso de crear nuevas muestras de datos a partir de los existentes mediante transformaciones como rotaciones, escalados, recortes, etc.
- Ayuda a mejorar la *generalización del modelo* y evita el overfitting, sobre todo cuando se tiene un dataset limitado.



Data augmentation

Si bien las capas convolucionales tienen la capacidad de generalizar (ser invariantes ante traslaciones, rotaciones u otras transformaciones), se le debe mostrar al modelo estos ejemplos para que logre aprender esas invarianzas



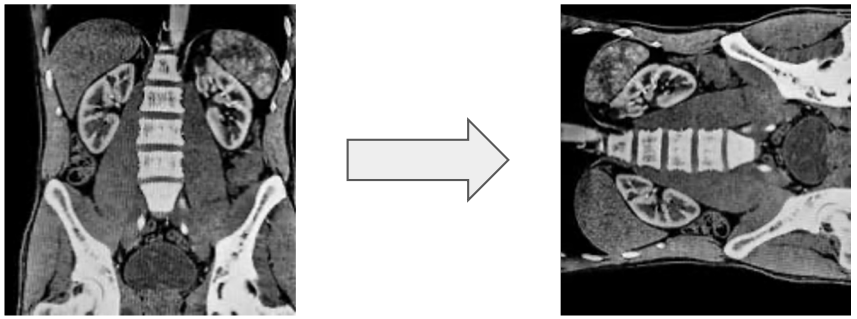
Data augmentation



Transformaciones más comunes (pensar en cuando esto tiene sentido)

- Rotación
- Traslación
- Zoom
- Flip Horizontal/Vertical

Data augmentation



A veces se hace más Data Augmentation del necesario. *En nuestro caso de uso, el modelo va a tener que ver tomografías computarizadas rotadas en 90 grados?*

En general es una buena herramienta, pero no queremos perder *poder predictivo* por aumentar exageradamente el poder de generalización frente a traslaciones, rotaciones, etc.

Data augmentation

Cómo se aplica en TensorFlow/Keras:

- Se puede implementar fácilmente usando *ImageDataGenerator*.

```
from tensorflow.keras.preprocessing.image import ImageDataGenerator

datagen = ImageDataGenerator(
    rotation_range=20,
    width_shift_range=0.2,
    height_shift_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True)

datagen.fit(x_train)
```

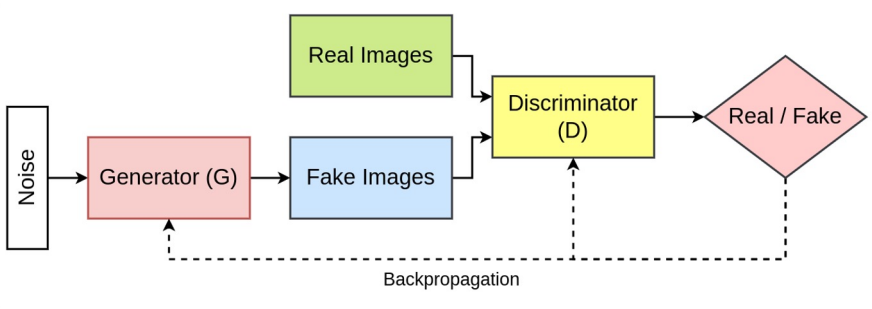
Otras arquitecturas basadas en CNNs

GANs

Redes Generativas Antagónicas (2014).

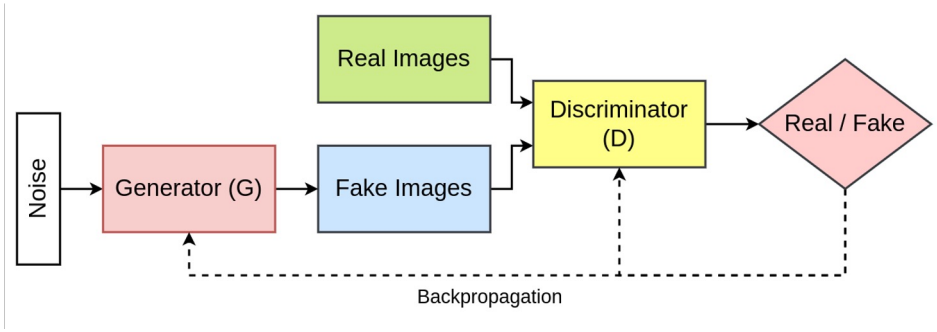
Dos redes neuronales que compiten:

- **Generador (G):** Su objetivo es aprender la distribución de probabilidad subyacente a los datos reales y generar nuevas muestras que sean indistinguibles de estos.
- **Discriminador (D):** Su objetivo es distinguir entre las muestras generadas por el generador y las muestras reales del conjunto de datos.



GANs: Generador

El generador toma como entrada un vector de ruido aleatorio. Este vector latente codifica la "semilla" para la generación de la nueva muestra. La arquitectura del generador suele estar diseñada para transformar este vector de baja dimensionalidad en un espacio de alta dimensionalidad que se asemeja al espacio de los datos reales (e.g., una imagen).

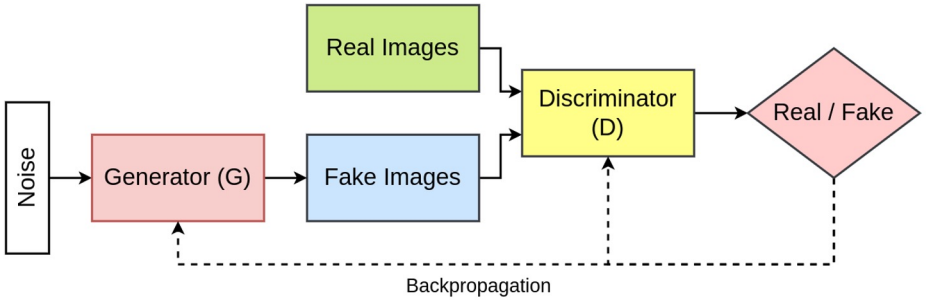


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

GANs: Generador

Las arquitecturas comunes para el generador incluyen **redes neuronales deconvolucionales** (también conocidas como capas de convolución transpuesta).

Estas capas realizan una operación inversa a la convolución, aumentando la dimensionalidad espacial de la representación.

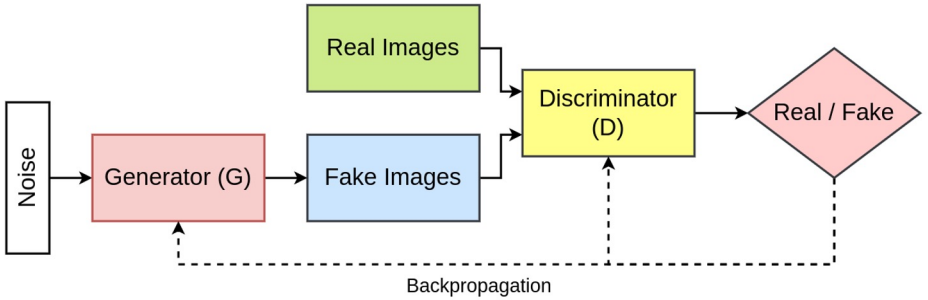


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

GANs: Discriminador

El discriminador recibe como entrada una muestra, que puede ser una muestra real del conjunto de datos de entrenamiento o una muestra generada por el generador **G(z)**.

Su arquitectura está diseñada para extraer características discriminativas de la entrada y realizar una clasificación binaria: determinar si la entrada es "real" o "falsa" (generada).

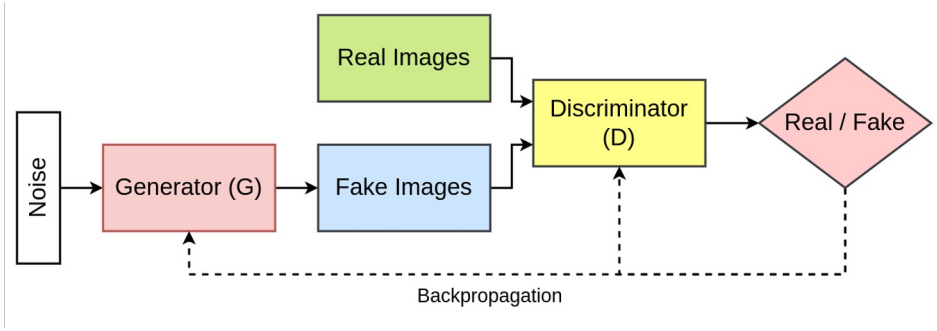


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

GANs: Discriminador

El discriminador típicamente emplea una arquitectura de red neuronal convolucional (CNN) estándar.

Las capas convolucionales extraen características jerárquicas, seguidas de capas de pooling para reducir la dimensionalidad y, finalmente, capas totalmente conectadas para la clasificación. La capa de salida del discriminador suele tener una única neurona con una función de activación sigmoide.

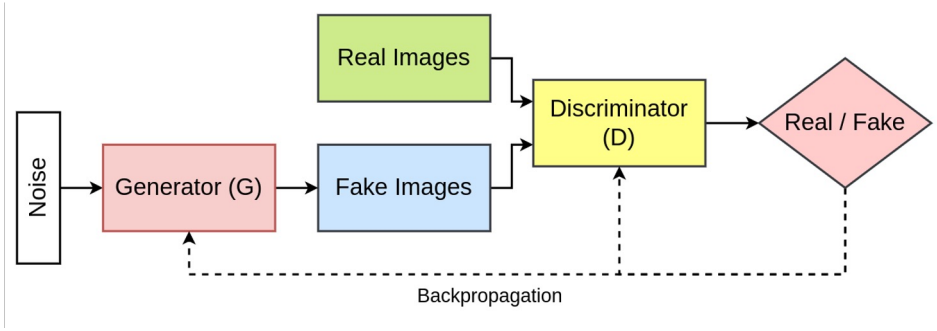


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

GANs: Discriminador

El discriminador típicamente emplea una arquitectura de red neuronal convolucional (CNN) estándar.

Las capas convolucionales extraen características jerárquicas, seguidas de capas de pooling para reducir la dimensionalidad y, finalmente, capas totalmente conectadas para la clasificación. La capa de salida del discriminador suele tener una única neurona con una función de activación sigmoide.

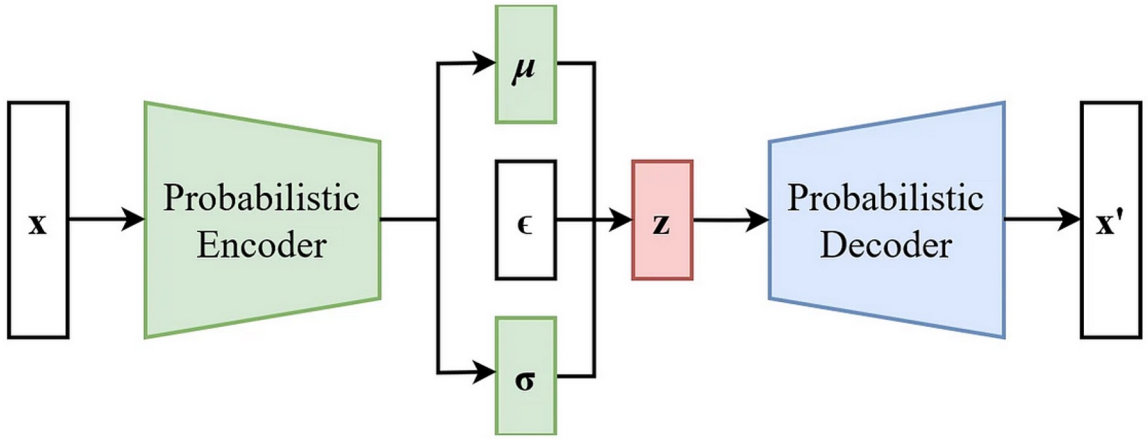


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

VAEs

Autoencoders Variacionales (2013).

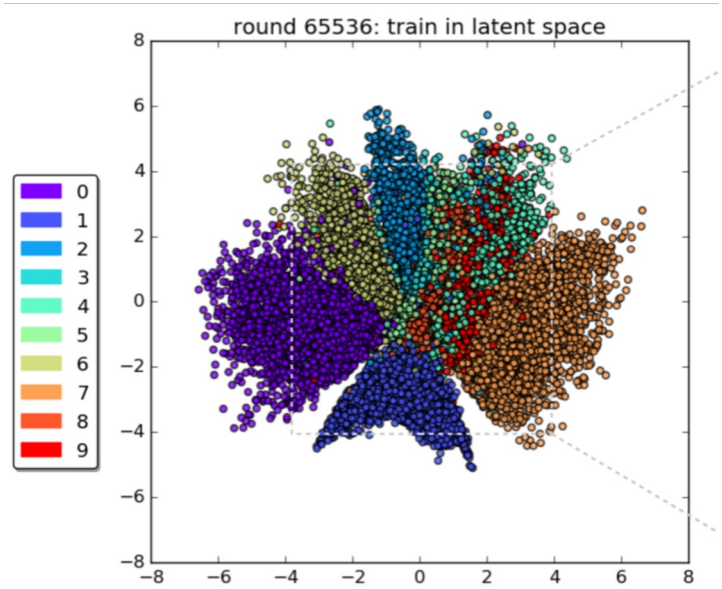
Los VAEs se basan en la **inferencia variacional** y el **modelado probabilístico**. Su objetivo es aprender una **representación latente** probabilística de los datos de entrada.



VAEs: Arquitectura

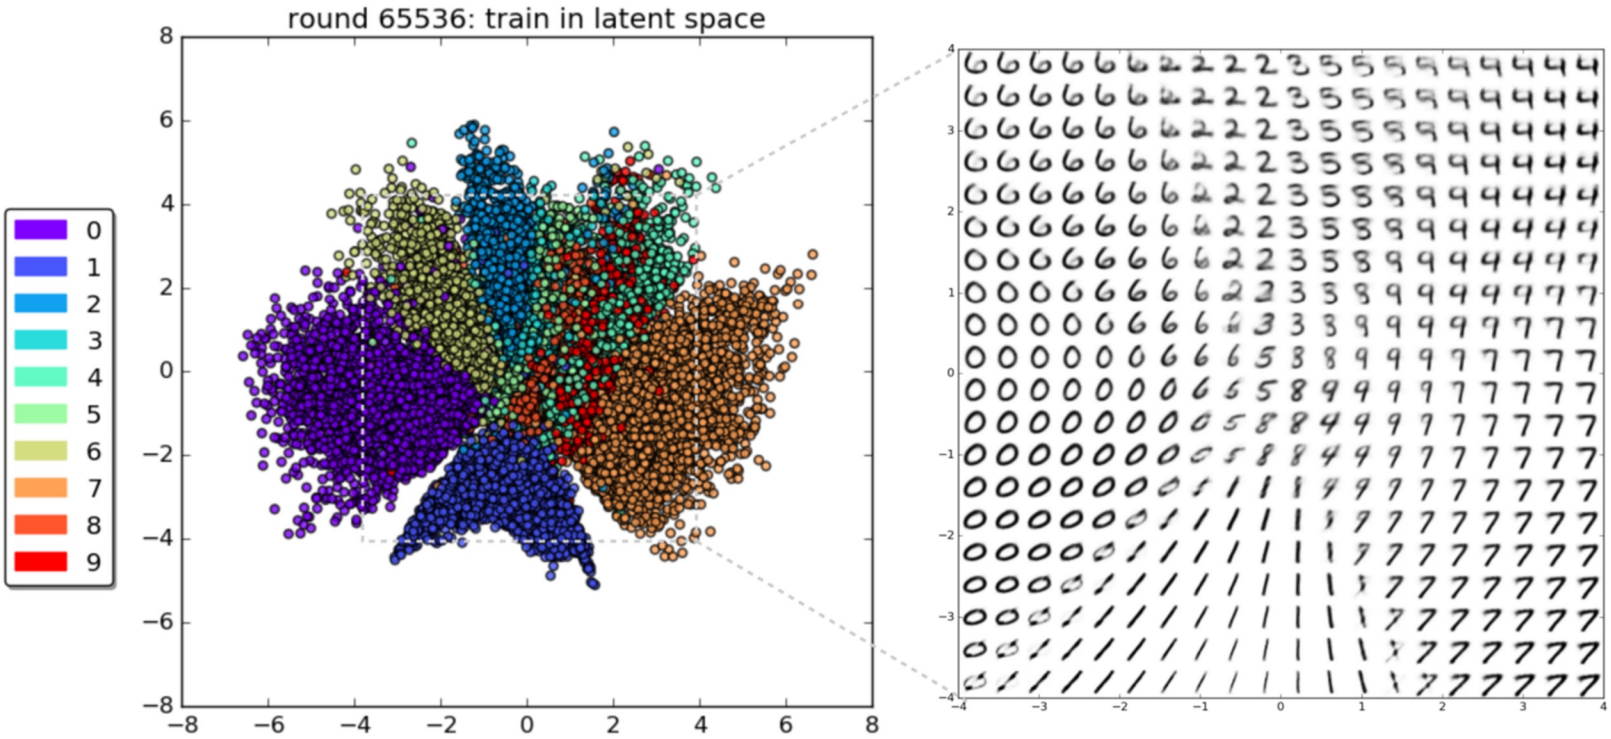
Un VAE consta de dos componentes principales:

- **Codificador (Encoder):** Mapea los datos de entrada **x** a una distribución de probabilidad en el espacio latente. **El codificador produce los parámetros de esta distribución** (típicamente la media y la varianza).
- **Decodificador (Decoder):** Toma una muestra **z** del espacio latente (obtenida de la distribución aprendida por el codificador) y la mapea de vuelta al espacio de datos, generando una reconstrucción **x'** de la entrada original o una nueva muestra similar.

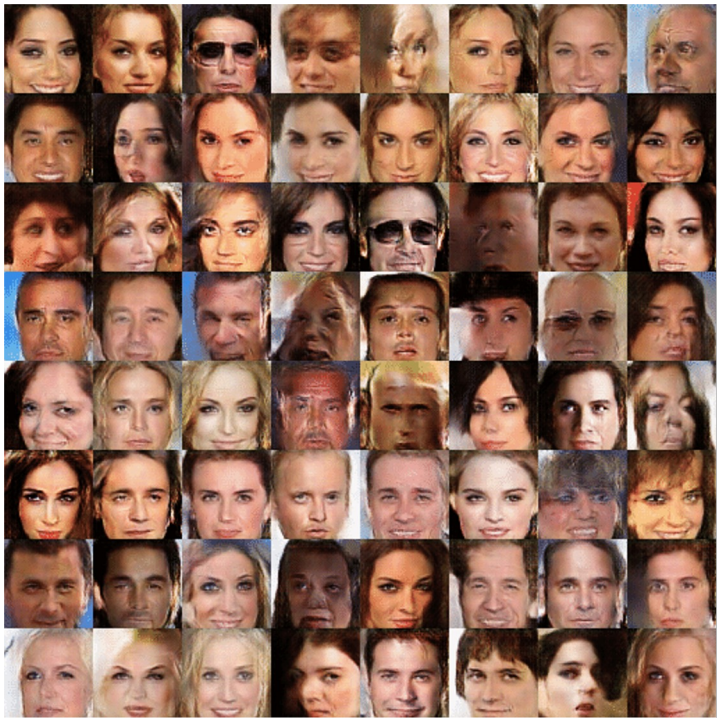


*La clave de los VAEs radica en aprender un **espacio latente** continuo y bien estructurado, lo que permite generar nuevas muestras significativas interpolando y muestreando en este espacio.*

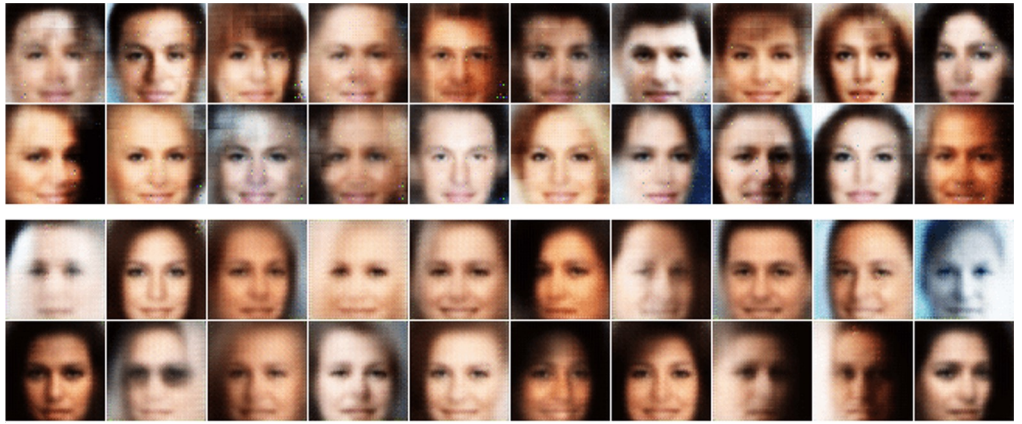
VAEs: Espacio Latente



Ejemplos



GANs



VAEs